

Heart Disease / Tarea 05

Nataly Huaiquinao, Carlos Ulloa
nhuaiquinao2021@alu.uct.cl, carlos.ulloa2020@alu.uct.cl

Tarea 5, INFO1184, Semestre I-2026

Resumen

El presente informe contiene el análisis del dataset *Heart Disease* obtenido desde el sitio web Kaggle (Nagarajan, 2020), el cual se compone de 1025 registros clínicos de pacientes con 13 variables fisiológicas. Nuestro objetivo es, mediante Mapas Autoorganizados de Kohonen (SOM), identificar perfiles naturales de pacientes, analizando mediante etapas de inicialización de pesos, estimación mediante entrenamiento iterativo, comparación de funciones de vecindad (kernel), visualización topológica y análisis de densidades y centroides. Realizamos la comparación de dos métodos de inicialización: aleatoria y basada en análisis de componentes principales. Así como también tres tipos de kernel: gaussiano, *bubble* y *mexican hat*. Los resultados obtenidos, demuestran que la inicialización PCA produce una convergencia más estable y un menor error de cuantización final. El mapa diferencia topológicamente a pacientes con y sin una enfermedad cardíaca y determina como variables discriminantes a la frecuencia cardíaca máxima, edad y depresión del segmento ST, esto concuerda con indicadores clínicos reconocidos.

1. Introducción

Una de las principales causas de mortalidad a nivel mundial, son las enfermedades cardiovasculares, es por esta razón que se vuelve de gran importancia la identificación temprana de perfiles de riesgo, tomando en cuenta determinados indicadores clínicos. Es en este contexto que las técnicas de aprendizaje no supervisado, nos permiten descubrir estructuras en los datos, sin requerir de algunas etiquetas predefinidas, lo que resulta especialmente útil cuando el objetivo es explorar patrones desconocidos (Kohonen, 2001). El conjunto de datos que utilizamos (*Heart Disease*), contiene registros clínicos de pacientes que se realizaron exámenes cardiovasculares, donde se muestran variables de indicadores fisiológicos básicos y resultados de pruebas. Realizamos el análisis siguiendo la metodología CRISP-DM, estructurando el trabajo en seis fases: comprensión de negocio, comprensión de los datos, preparación de los datos, modelamiento, evaluación y despliegue.

Con la realización de este informe buscamos saber si es posible identificar grupos de pacientes, con perfiles clínicos similares, si existen variables clínicas que nos permitan determinar los principales factores para pacientes con y sin enfermedades cardíacas y como comprender como influye el método de inicialización de pesos con el tipo de kernel en la calidad del mapa de Kohonen.

2. Fundamentos de teoría

Mapas Autoorganizados de Kohonen (SOM): Es una red neuronal no supervisada propuesta por Kohonen (Kohonen, 2001), el cual proyecta datos de alta dimensionalidad sobre una grilla bidimensional de neuronas, manteniendo la relación topológica del espacio original. Cada neurona, posee un vector de peso $\mathbf{w}_i \in R^d$, donde d es la dimensión de entrada.

Inicialización de pesos: Se puede iniciar aleatoriamente desde $\mathcal{U}(0, 1)$ o mediante los primeros componentes (PCA-init), los cuales estructuran los pesos según la máxima varianza de los datos y aceleran la convergencia (Kohonen, 2001).

Estimación de pesos: En cada iteración, se determina la neurona ganadora (*Best Matching Unit*, BMU):

$$\text{BMU} = \arg \min_i \|\mathbf{x} - \mathbf{w}_i\| \quad (1)$$

Los pesos se actualizan según la regla de aprendizaje:

$$\mathbf{w}_i(t+1) = \mathbf{w}_i(t) + \eta(t) \cdot h_{ci}(t) \cdot (\mathbf{x}(t) - \mathbf{w}_i(t)) \quad (2)$$

donde $\eta(t)$ representa la tasa de aprendizaje decreciente y $h_{ci}(t)$ es la función de vecindad.

Kernel o función vecindad: Este, determina la influencia de *BMU* sobre las neuronas circundantes. La función gaussiana es:

$$h_{ci}(t) = \exp\left(-\frac{d(c,i)^2}{2\sigma(t)^2}\right) \quad (3)$$

donde $d(c,i)$ se refiere a la distancia topológica entre la *BMU* c y la neurona i , y $\sigma(t)$ es el radio decreciente. La función *bubble* aplica influencia uniforme dentro del radio y nula fuerza; la función *mexican hat* refuerza la inhibición lateral (Haykin, 1999)

Error de cuantización: Este error mide la calidad del mapa como distancia promedio entre cada observación y su *BMU*

$$E_q = \frac{1}{N} \sum_{j=1}^N \|\mathbf{x}_j - \mathbf{w}_{\text{BMU}(j)}\| \quad (4)$$

U-Matrix: Es la visualización de la distancia promedio entre los pesos las neuronas adyacentes, lo que permite identificar las fronteras entre las agrupaciones.

3. Desarrollo del trabajo

3.1. Comprensión del problema

El objetivo es identificar perfiles clínicos diferenciados en pacientes cardiovasculares, mediante técnicas de aprendizaje no supervisado, sin utilizar la variable de diagnóstico durante el entrenamiento.

Definimos el problema como: ¿Existen grupos de pacientes que compartan características clínicas similares?, ¿qué variables determinan estos grupos?. Usaremos un Mapa de Kohonen, para tratar los registros, evaluaremos la calidad del mapa mediante el error de cuantización y analizaremos la distribución topológica de los pacientes, para de esta manera responder las preguntas de investigación planteadas.

3.2. Comprensión de los datos

Utilizamos el dataset *Heart Disease*, obtenido desde el sitio web público Kaggle (?, ?), el cual contiene 1025 registros con 14 columnas; *13 variables predictoras y una variable objetivo* (0: sin enfermedad, 1: con enfermedad).

La siguiente tabla 1, se observan las 13 variables de entrada, donde notamos que la variable objetivo es balanceada: encontramos 499 pacientes sin enfermedad y 526 pacientes con enfermedad cardiovascular. No se encontraron valores nulos entre los datos.

Variable	Descripción	Tipo	Rango
age	Edad (años)	Numérica	29 – 77
sex	Sexo (0: femenino, 1: masculino)	Binaria	{0, 1}
cp	Tipo de dolor de pecho	Catagórica	0 – 3
trestbps	Presión arterial en reposo (mmHg)	Numérica	94 – 200
chol	Colesterol sérico (mg/dL)	Numérica	126 – 564
fbs	Glucosa en ayunas >120 mg/dL	Binaria	{0, 1}
restecg	Resultado ECG en reposo	Catagórica	0 – 2
thalach	Frecuencia cardíaca máxima (bpm)	Numérica	71 – 202
exang	Angina inducida por ejercicio	Binaria	{0, 1}
oldpeak	Depresión segmento ST (mm)	Numérica	0 – 6,2
slope	Pendiente segmento ST	Catagórica	0 – 2
ca	Vasos coloreados (fluoroscopia)	Numérica	0 – 4
thal	Resultado talasemia	Catagórica	0 – 3

Cuadro 1: Variables del dataset Heart Disease Kaggle y sus características

3.3. Preparación de los datos

Excluimos la variable `target` del entrenamiento de la *SOM*, para utilizarla finalmente solo en la etapa de validación posterior de los grupos encontrados. Luego transformamos las variables predictoras, normalizando al rango $[0, 1]$ mediante *MinMaxScaler*

$$x'_j = \frac{x_j - x_{\min}}{x_{\max} - x_{\min}} \quad (5)$$

Con respecto a las variables categóricas ordinales (`cp`, `restecg`, `slope`, `thal`), las utilizamos como variables numéricas después de la normalización, debido a que sus valores reflejan un orden clínico natural. Finalmente obtenemos, una matriz $X \in \mathbb{R}^{1025 \times 13}$.

3.4. Modelamiento

Comenzamos aplicando las cinco etapas del Mapa de Kohonen:

3.4.1. Inicialización de pesos de la red

Determinamos el tamaño del mapa, mediante la regla heurística $\lceil \sqrt{5\sqrt{N}} \rceil$, obteniendo como resultado una grilla de $13 \times 13 = 169$ neuronas.

Comparamos dos métodos de inicialización con los hiperparámetros: $\sigma_0 = 1,5$ y $\eta_0 = 0,5$.

Inicialización aleatoria Extraemos los pesos de $\mathcal{U}(0, 1)$ sin considerar la estructura de los datos. En los boxplots de la Figura 1 (derecha) evidencia distribuciones más compactas y centradas: variables como *Angina por ejercicio* y *Depresión ST* toman valores negativos, coherente con las direcciones de los componentes principales.




Figura 1: Distribución de pesos iniciales por variable: inicialización aleatoria (izquierda) y por PCA (derecha).

3.4.2. Estimación de los pesos

Ambos *SOM* se entrenaron con 500 épocas, actualizando los pesos neurona por neurona en cada dato. La tasa de aprendizaje y el radio decrecen linealmente: $\eta(t) = \eta_0 (1 - t/T)$ y $\sigma(t) = \sigma_0 (1 - t/T)$.

Estimación de pesos Convergencia del Error de Cuantización




Figura 2: Convergencia del error de cuantización

En la Figura 2 notamos trayectorias distintas. La inicialización aleatoria comienza con $E_q \approx 0,29$, asciende hasta $\approx 0,57$ en la época 40 por reorganización caótica inicial, luego desciende. En la inicialización PCA converge monótonicamente desde $E_q \approx 0,74$, llegando a un error final de **0,4154** versus 0,4213 de la aleatoria. Por lo tanto PCA-init produce una representación más precisa de datos.

3.4.3. Kernel/Función de vecindad

Entrenamos tres *SOM* independientes variando solamente la función vecindad, la inicialización PCA y demás hiperparámetros los mantuvimos constantes.




Figura 3: U-Matrix según tipo de kernel: Gaussiana, Bubble y Mexican Hat.

En la Figura 3 visualizamos diferencias estructurales relevantes. Donde el **Kernel Gaussiano** produce transiciones suaves con fronteras graduales, esto nos facilita la identificación de las zonas de transición entre los diferentes perfiles clínicos. Por otro lado, **Kernel bubble** genera patrones más discontinuo, debido a que aplica influencia uniforme dentro del radio σ . Finalmente, **Kernel mexican hat**, no logra activar la grna parte del mapa y concentra la variación en un núcleo central,

esto indicaría que se requiere un ajuste de σ para este dataset. En nuestro caso, seleccionamos el **Kernel gaussiano** para realizar los análisis de visualización y densidad.

3.4.4. Visualización

La Figura 5 muestra tres visualizaciones complementarias del mapa entrenado.

U-matrix con proyección de pacientes muestra que los pacientes con enfermedad cardíaca (*triángulos rojos*) se concentran en la zona superior izquierda del mapa, en caso contrario (*círculos verdes*) se concentran en la zona inferior derecha con frontera topológica visible en las columnas 4 a 7. Lo cual nos confirma que es posible identificar grupos de pacientes con perfiles similares. Los **Component planes** muestra los patrones por variables, donde la edad es mayor en la zona de enfermedad, la frecuencia cardíaca máxima muestra valores altos en pacientes sanos, y la depresión ST presenta valores elevados en zonas de riesgo. Esto indica que las variables más discriminantes son frecuencia cardíaca máxima, edad y depresión ST.

El **Mapa de proporción por clase** confirma la separación, en zonas rojas se encuentra una alta proporción de pacientes enfermos y en zonas verdes se concentra la proporción de pacientes sanos.

3.4.5. Densidades y centroides




Figura 4: Hit map de densidades, centroides en espacio PCA y perfil clínico de las 5 neuronas más densas.

El **Hit-map** 4 muestra que la neurona más poblada es N (8,7) con 32 pacientes, seguido de N(5,4) y N(7,4) con 22 y 21 respectivamente (distribución no uniforme). Concentrando la densidad en la zona centro-izquierda del mapa. En el **Espacio PCA** ($PC1 = 27,2\%$, $PC2 = 18,5\%$, varianza acumulada = $45,7\%$), los centroides forman una diagonal que separa las clases con los pacientes enfermos en la parte superior y los pacientes sanos en la parte inferior. En la Tabla 2se muestra el resumen de las 5 neuronas más densas, donde todas corresponden a perfiles de bajo riesgo (47 a 55 años, presión arterial moderada, colesterol entre 187 y 256 mg/dL, frecuencia cardíaca máxima alta (149–175 bpm) y depresión DT casi nula (0–1 mm), características asociadas clínicamente a pacientes sanos (Thygesen y cols., 2018)

Cuadro 2: Perfil clínico de las 5 neuronas más densas (valores desnormalizados)

Neurona	Edad	Presión (mmHg)	Colesterol (mg/dL)	FC máx (bpm)	Dep. ST (mm)
N(8,7) $n = 32$	54,5	138,5	256,3	149,0	0,5
N(5,4) $n = 22$	47,3	125,7	227,5	175,0	0,2
N(7,4) $n = 21$	52,2	124,1	232,0	162,0	0,8
N(6,1) $n = 21$	47,0	118,9	231,7	161,4	0,2
N(0,0) $n = 19$	55,3	144,9	186,6	168,5	0,4

3.5. Evaluación

Evaluamos si el modelo logra los objetivos establecidos en la Fase 1:

El SOM con Kernel gaussiano e inicialización de PCA, alcanza un error de 0,4154, lo que indicaría una representación adecuada del espacio de datos con 169 neuronas para 1025 observaciones.

La separación topológica observada entre los dos tipos de pacientes valida la utilidad del modelo para el objetivo planteado, por otro lado, los componet planes identifican correctamente las variables de mayor relevancia, coherentes con la literatura médica (Thygesen y cols., 2018).

Sin embargo, identificamos que el tratamiento de variables categóricas como numéricas puede generar sesgo en las distancias euclidianas. Para mejorar este ámbito, sería incorporar la distancia de Gower para variables mixtas.

3.6. Despliegue

Estos resultados, se pueden usar como insumo para un sistema de apoyo al diagnóstico clínico.

El mapa entrenado, permite clasificar nuevos pacientes, dado un vector $\mathbf{x}^*$, el cual determina su BMU y consulta la zona del mapa a la cual pertenece, para estimar su perfil de riesgo.

El código de esta simulación se encuentra disponible en repositorio Github indicado en Anexo. Para mejorar el uso sería recomendable reentrenar el modelo con una mayor cantidad de datos y validar la separación topológica integrando nuevas métricas.

4. Discusión y reflexión

Seguindo la metodología CRISP-DM, estructuramos el análisis de forma ordenada, notamos que la combinación de variables mixtas, condiciona las decisiones de preprocesamiento. Para poder mantener la interpretación de los pesos, decidimos tratar las variables categóricas con normalización directa, en vez de codificación one-hot. Por otro lado, en cuanto a los resultados, confirmamos que la elección de kernels no es una decisión trivial, ya que el *mexican hat* produjo un mapa degenerado con parámetros estándar, lo que indica que la calibración de hiperparámetros es una parte fundamental. Finalmente y evaluando los resultados, observamos que el error de cuantización mide la fidelidad de representación, pero no la calidad de la separación entre los grupos. Por lo que en investigaciones futuras sería bueno integrar y evaluar índice de error topográfico y métrica de pureza de clúster.

5. Conclusiones

Conclusión de Nataly Huaiquinao

La aplicación de CRISP-DM junto a Mapas de Kohonen, generan una estructuración que mejora la calidad del análisis. Además la separación topológica confirma que el SOM captura patrones clínicos reales, lo cual convierte este método en una herramienta válida para la exploración de datos médicos, generando así una mayor eficacia en el diagnóstico y prevención de enfermedades.

Conclusión de Carlos Ulloa

El realizar una comparación en los métodos de inicialización, evidenció que PCA-init elimina la fase de reorganización caótica que observamos en init aleatoria. Esto se vuelve especialmente valioso en la aplicación clínica, donde la reproducibilidad del modelo es una prioridad.

6. Referencias

Referencias

Haykin, S. (1999). *Neural networks: A comprehensive foundation* (2.^a ed.). Prentice Hall.

Kohonen, T. (2001). *Self-organizing maps* (3.^a ed.). Springer-Verlag.

Nagarajan, S. (2020). *Heart disease dataset*. Kaggle. Descargado de <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Thygesen, K., y cols. (2018). Fourth universal definition of myocardial infarction. *Journal of the American College of Cardiology*, 72(18), 2231–2264.

A. Anexo




Figura 5: Visualización del Mapa de Kohonen: U-Matrix con pacientes proyectados, *component planes* por variable y mapa de proporción de pacientes con enfermedad.

Links de interés:

- Github Tarea 05

A.1. Bitácora de trabajo

- Día 1 (2026-06-02): Selección del dataset, Análisis exploratorio de datos.
- Día 2 (2026-06-03): Preprocesamiento y normalización de variables. Implementación de código.
- Día 3 (2026-06-05): Evaluación y discusión de resultados. Generación de informe.